



OPTIMISATION POUR LE MACHINE LEARNING

PROJET D'EXAMEN FINAL

Filière : Master SSD

Date : Janvier 2026

Note : *Ce projet est à réaliser individuellement. La rigueur mathématique dans la rédaction en $\LaTeX$, la qualité des implémentations Python sur des datasets de grande taille et l'analyse critique des résultats seront les principaux critères d'évaluation.*

Objectifs :

Ce projet vise à évaluer la maîtrise des quatre piliers du cours : la modélisation (Chap. 1), les méthodes de gradient déterministes (Chap. 2), le passage à l'échelle via la stochasticité (Chap. 3) et l'optimisation non lisse par algorithmes proximaux (Chap. 4).

Exercice 1: Modélisation et Étude Théorique (6 points)

On considère un problème de régression sur le dataset *YearPredictionMSD* ($n \approx 515\,000$ exemples, $d = 90$) visant à prédire l'année de sortie d'une chanson. Soit X la matrice des données et y le vecteur cible.

- Modélisation :** Formuler le problème de minimisation sous la forme d'une somme finie $f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w)$. Justifiez l'ajout d'une pénalité $\frac{\mu}{2} \|w\|^2$ pour garantir l'unicité du minimum global en citant le **Théorème 1.2.9** du cours.
- Étude du Gradient :** Calculer analytiquement le gradient $\nabla f(w)$ et la matrice Hessienne $\nabla^2 f(w)$.
- Lipschitz et SVD :** En utilisant la Décomposition en Valeurs Singulières (SVD) de X vue au Chapitre 2, déterminer l'expression de la constante de Lipschitz L du gradient. Quel est l'impact de cette constante sur la stabilité de la descente de gradient ?

Exercice 2: Stochasticité et Passage à l'Échelle (7 points)

Compte tenu de la taille du dataset ($n > 500\,000$), le calcul du gradient complet est proscrit.

- Implémentation SGD :** Coder l'algorithme de Descente de Gradient Stochastique *from scratch*. Prouvez mathématiquement que $\mathbb{E}[\nabla f_i(w)] = \nabla f(w)$ (estimateur sans biais).

- b) **Analyse Comparative** : Comparer la convergence (MSE vs Temps CPU) entre le Gradient de Batch (sur un sous-échantillon) et le SGD. Illustrer le phénomène de "bruit de gradient" via des graphiques.
- c) **Mini-batch et Adam** : Implémenter une variante Mini-batch et comparez ses performances avec l'algorithme **Adam**. Discutez de l'importance de la standardisation des données pour la condition de la Hessienne.

Exercice 3: Parcimonie et Algorithmes Proximaux (7 points)

On s'intéresse à la classification de documents sur le dataset *Reuters RCV1* où la dimension est très élevée et les variables redondantes.

- a) **Analyse Géométrique** : Expliquer, schémas à l'appui, pourquoi la régularisation L_1 (Lasso) est préférable à la régularisation L_2 pour obtenir un modèle interprétable en haute dimension.
- b) **ISTA** : Définir et implémenter l'opérateur proximal de la norme L_1 (*Soft-thresholding*). Utilisez-le pour coder l'algorithme ISTA.
- c) **Accélération** : Implémenter l'algorithme accéléré **FISTA**. Comparez le taux de convergence théorique $O(1/k)$ d'ISTA par rapport au $O(1/k^2)$ de FISTA.
- d) **Sélection de variables** : Identifier les mots (caractéristiques) les plus significatifs pour la classification en faisant varier le paramètre de régularisation λ .

Livrables attendus

- Un rapport rédigé en $\text{\LaTeX}$ présentant de manière rigoureuse les justifications théoriques (comme indiqué en cours, l'aspect théorique est privilégié par rapport à l'implémentation pratique).
- Un notebook (Python) contenant les implémentations et les visualisations demandées.
- Une analyse comparative des temps de calcul et des taux de convergence pour chaque méthode.